

Práctica 3: Análisis de Eficiencia en Logística Global

Asignatura: Ciencia de Datos | **Ingeniería en Sistemas Computacionales**

1. Contexto Profesional

La empresa "Global-Logistics ISC" utiliza dos modalidades de transporte para sus envíos nacionales: **Terrestre** y **Aéreo**. La gerencia de operaciones ha notado retrasos y sospecha que el tiempo de entrega no solo depende de la distancia, sino de ineficiencias en la modalidad de transporte bajo ciertas condiciones climáticas. Tu misión es analizar los datos de los últimos 600 envíos para determinar dónde están los cuellos de botella.

2. Objetivo

Validar de forma independiente la capacidad de limpiar datos, realizar análisis exploratorio, agrupar información y aplicar pruebas de hipótesis para la toma de decisiones basada en datos.

3. Requerimientos

- Entorno: **RStudio**.
- Librerías: `tidyverse` (`dplyr`, `ggplot2`).
- Dataset: Simulación de 600 registros generada en el script.

```
> library(tidyverse)
— Attaching core tidyverse packages — tidyverse 2.0.0 —
✓ dplyr      1.2.0    ✓ readr      2.1.6
✓ forcats    1.0.1    ✓ stringr    1.6.0
✓ ggplot2    4.0.2    ✓ tibble     3.3.1
✓ lubridate  1.9.5    ✓ tidyr      1.3.2
✓ purrr      1.2.1
— Conflicts — tidyverse_conflicts() —
✖ dplyr::filter() masks stats::filter()
✖ dplyr::lag()     masks stats::lag()
i Use the conflicted package to force all conflicts to become errors
> |
```

4. Tareas a realizar por el alumno

Fase 1: Calidad de Datos

1. **Limpieza:** El dataset contiene valores NA en la columna `distancia_km` debido a fallas en el GPS. Imputa estos valores usando la **mediana**.
2. **Descriptivos:** Calcula la media y desviación estándar del `tiempo_entrega_hrs`.

```
> set.seed(123)
>
> # Crear dataset de 600 registros
> envios <- data.frame(
+   distancia_km = sample(50:2000, 600, replace = TRUE),
+   tipo_transporte = sample(c("Terrestre", "Aereo"), 600, replace = TRUE),
+   clima = sample(c("Normal", "Lluvia", "Tormenta"), 600, replace = TRUE),
+   costo = round(runif(600, 500, 5000), 2)
+ )
>
> # Simular tiempo de entrega
> envios$tiempo_entrega_hrs <- envios$distancia_km/60 + rnorm(600, 5, 2)
>
> # Introducir valores NA en distancia
> indices_na <- sample(1:600, 30)
> envios$distancia_km[indices_na] <- NA
>
> head(envios)
  distancia_km tipo_transporte clima  costo tiempo_entrega_hrs
1         464      Terrestre Lluvia 1498.25      12.793631
2         512      Terrestre Lluvia 4329.33      12.689336
3         228      Terrestre Lluvia 1703.06       8.305150
4         575        Aereo Normal 3193.70      15.871636
5         244        Aereo Normal 3238.70       9.503693
6          NA        Aereo Lluvia 4964.71      24.499809
>
> # Calcular mediana
> mediana_distancia <- median(envios$distancia_km, na.rm = TRUE)
>
> # Reemplazar NA
> envios$distancia_km[is.na(envios$distancia_km)] <- mediana_distancia
> # Media
> media_tiempo <- mean(envios$tiempo_entrega_hrs)
>
> # Desviación estándar
> desv_tiempo <- sd(envios$tiempo_entrega_hrs)
>
> media_tiempo
[1] 22.12661
> desv_tiempo
[1] 9.62528
> |
```

Fase 2: Análisis de Relaciones

1. **Correlación:** Calcula el coeficiente de Pearson entre `distancia_km` y `tiempo_entrega_hrs`. ¿Es la relación tan fuerte como se esperaba?

```
> correlacion <- cor(envios$distancia_km, envios$tiempo_entrega_hrs)
>
> correlacion
[1] 0.9557525
> |
```

Fase 3: Comparativa de Modalidades

1. **Agrupación:** Agrupa por `tipo_transporte` y obtén el promedio de tiempo de entrega y el costo promedio.
2. **Prueba de Hipótesis:** Aplica un **t-test** para determinar si existe una diferencia significativa entre el tiempo de entrega del transporte **Terrestre** vs **Aéreo**.

```
> envios %>%
+   group_by(tipo_transporte) %>%
+   summarise(
+     tiempo_promedio = mean(tiempo_entrega_hrs),
+     costo_promedio = mean(costo)
+   )
# A tibble: 2 × 3
  tipo_transporte tiempo_promedio costo_promedio
  <chr>           <dbl>         <dbl>
1 Aereo           22.7         2757.
2 Terrestre       21.6         2729.
> |
```

Fase 4: Visualización

1. Genera un **Gráfico de Dispersión** que muestre la relación entre distancia y tiempo, diferenciando los puntos por modalidad de transporte.
2. Crea un **Boxplot** para comparar los tiempos de entrega entre modalidades e identificar valores atípicos (envíos extremadamente retrasados).



